

Qwen3.5-27B 精简优化实现分工

本文给出 pra2026-bh408-gqa-page784-k5120 的闭卷实现分工。实现方法遵循 pra2026-bh408-modular/docs/csccl/CLOSED_BOOK_HIGH_IMPACT_CHEATSHEET.md：每项优化只记住并维护四件事——官方入口、目标 shape、fast path、官方 fallback。

1. 基线与范围

1.1 官方 upstream 与实际 OpenDAS 基线

本文所称“官方基线”是比赛提供的 OpenDAS vLLM 源码 fa718036bdb9dfd80a872b86c8ac16c9d02bfd31。它声明的包版本是 vLLM 0.18.1，但它是带 DCU/OpenDAS 修改的 downstream commit，不等于 upstream vLLM 0.18.1 tag 的 commit。实现时以 fa718036 的文件内容为最终基准，upstream URL 用于理解官方设计。

项目	详细版本	URL
vLLM upstream 仓库	vLLM Team, Apache-2.0	https://github.com/vllm-project/vllm
upstream 发布版	v0.18.1，tag commit a26e8dc7ff2111a005144d775ecf9cebf56c45b2	https://github.com/vllm-project/vllm/releases/tag/v0.18.1
upstream 固定源码	tag v0.18.1	https://github.com/vllm-project/vllm/tree/v0.18.1
upstream 固定文档	vLLM 0.18.1	https://docs.vllm.ai/en/v0.18.1/
比赛/ OpenDAS 基线	commit fa718036bdb9dfd80a872b86c8ac16c9d02bfd31；本地 ref refs/baselines/opendas-v0.18.1；提交时间 2026-04-13T21:02:44+08:00	https://gitlab.eduxiji.net/T2026100069912215/pra2026-bh408/-/commit/fa718036bdb9dfd80a872b86c8ac16c9d02bfd31
当前精简实现	branch repro-gqa-page784-k5120；优化提交 0e764a1cd6fba986be35edbc64cbd531154e24f4	https://github.com/cspool/dcu-home/tree/repro-gqa-page784-k5120

OpenDAS setup.py 把 Python 包基础版本固定为 0.18.1，并按构建环境形成以下 wheel 版本：

```
默认          0.18.1+das
ADD_GIT_VERSION=1  0.18.1+das.<7位提交号>
同时设置 ROCM_PATH 0.18.1+das[.<提交号>].dtk2604
```

基线与当前验证环境的详细依赖如下：

类别	版本/约束
Python 声明	>=3.10,<3.14；当前环境 3.10.12
PyTorch	基线严格固定 2.10.0；当前环境 2.10.0
torchvision	0.25.0
flash-attn	OpenDAS要求 2.8.3；当前环境 2.8.3+das.opt1.dtk2604.torch2100.20260330.g3f0061
Triton	OpenDAS源码构建约束为 3.6.0；当前比赛容器预装DCU版本 3.4.0+git1ef59765

类别	版本/约束
AITER	当前比赛容器预装 0.1.dev1+g9daa788.d20260401；官方attention backend原本已使用
HIP runtime	当前 6.3.26093
DTK	当前 26.04，wheel 后缀写作 dtk2604
HCU target	gfx936:sramecc+:xnack-

page784 使用的公开入口 flash_attn.varlen_fwd_unified 来自上述外部 wheel，最终调用已编译的 flash_attn_2_cuda。它是OpenDAS环境声明并预装的DCU版本，不是本仓库 内置源码，也不是三人自行从公开PyPI下载的CUDA wheel。只修改本项目的page784调用不需要 重编FlashAttention。

这里的“官方提供”是指比赛/OpenDAS源码或比赛容器提供，不表示所有组件都由vLLM项目 自行开发。四组优化没有引入新的第三方依赖：

使用方	依赖	来源	当前容器是否需要额外下载
A: GQA6、GDN	torch、vllm.triton_utils 及其Triton	OpenDAS官方源码入口；PyTorch/Triton由比赛容器预装	否
B: page784	上述依赖，加 flash_attn 和 flash_attn_2_cuda	requirements/rocm.txt 正式声明；比赛容器预装DCU wheel	否
C: K5120/SwiGLU	PyTorch C++ ABI、HIP/DTK、CMake、Ninja；本仓库 _rocm_C 源码	OpenDAS仓库和比赛容器	否
公共官方 fallback	AITER	OpenDAS官方backend原本已有；比赛容器预装	否

因此，在当前比赛容器中禁止为本分支另行执行 pip install triton、pip install flash-attn、git clone 第三方 kernel或下载公开CUDA wheel。Triton源码约束与 容器实装版本不同不是本分支的新依赖；当前算子已用容器预装版本验证，应以比赛镜像为准，不能由个人替换。若上述import或 hipcc/cmake/ninja 缺失，应判定容器不匹配并恢复官方 环境，而不是自行补包。ROCm/HIP构建只编译仓库已有源码；CMake中的外部FetchContent 分支只在CUDA构建启用，本目标不会下载这些依赖。

读取代码时优先使用精确 baseline object，而不是从当前 HEAD 反推官方实现：

```
OFFICIAL=fa718036bdb9dfd80a872b86c8ac16c9d02bfd31
git show "$OFFICIAL":vllm/v1/attention/backends/rocm_aiter_unified_attn.py
git show "$OFFICIAL":vllm/model_executor/models/qwen3_5.py
git show "$OFFICIAL":csrc/rocm/skinny_gemms.cu
```

1.2 本文实现范围

- 本文行号对应应在优化提交 0e764a1cd6fba986be35edbc64cbd531154e24f4 之上完成的 attention执行路径拆分；代码变化后仍应优先按函数名定位。
- 目标环境：单卡 gfx936、Qwen3.5-27B、BF16、TP/PP/DP=1。
- 模型配置：hidden size 5120，64 层，Q24/KV4，attention head dim 256，GDN K/V head 数为 16/48、head dim 为 128，MLP intermediate size 为 17408。
- 本文只覆盖 GQA6、page784、GDN RMSNorm+SiLU、K5120 GEMV 和 GateUp/SwiGLU；不覆盖 GDN 固定 schedule、K17408、TunableOp 或 M-RoPE。
- 本版可执行实现 churn 为 626 行；经确认允许相对原 600 行目标超出 26 行。 docs/ 和代码注释不计入该口径。代码行号变化后应优先按函数名定位，不应机械依赖旧行号。

任何 fast path 只接管已经验证的输入。不匹配时必须返回 `False / None`，或从宿主函数 继续执行官方实现，不能让优化条件改变非目标输入的行为。

2. 总体责任边界

行数使用 cheatsheet 的 runtime churn 口径：相对 `fa718036` 的 additions 和 deletions 均计入工作量，不是净新增行数；本表排除后来按要求补充的注释。可执行实现是 608 additions + 18 deletions = 626，允许超过原目标 26 行。物理 diff 另含 77 行 调用链/职责/工作逻辑注释，因此不能直接用最终 `git diff --numstat` 反推本表。

人员	负责代码行数	语言	行数分解	主责
A	215	Python; Triton Python DSL	GQA6 完整路径 123; ROCm backend gate/router与AITER 适配60; GDN helper 与 Qwen 接入 churn 32	GQA6; attention 公共入口; GDN RMSNorm+SiLU
B	215	Python; Triton Python DSL	page784 完整路径 215	page784 gate、数据准备、两次 FlashAttention 与 LSE merge
C	196	HIP C++ 125; Python 71	<code>skinny_gemms.cu</code> churn 125; gfx936 公共门/K5120、linear/MLP/setup Python churn 71	公共 gfx936 门; K5120; GateUp/SwiGLU; ROCm extension 构建
合计	626	Python、Triton Python DSL、HIP C++	608 additions + 18 deletions; 注释另计 77 行但不进入预算	本分支全部运行时优化

责任排除项：A 不负责 page784 内部实现或 K5120；B 不负责 GQA6、attention 宿主 gate、GDN epilogue 或 native GEMV；C 不负责 Attention、GDN Norm+SiLU 或 K17408 down projection。

attention 按执行路径拆成独立文件，不再从函数中间划分负责人：

- `rocm_aiter_unified_attention_gqa6.py`：A 独立负责 GQA6 kernel 与 host launch。
- `rocm_aiter_unified_attention_page784.py`：B 独立负责从 gate、pack 到两次 FlashAttention 和 LSE merge 的完整 page784 路径。
- `rocm_aiter_unified_attn.py`：A 是 attention 公共入口 owner；先调用 B 的 page784，返回 `False` 时再调用 A 的 GQA6，宿主 gate 不命中时继续官方实现。
- `gfx936.py`：C 是文件 owner，负责模块骨架、公共 `is_gfx936` 和 K5120；A 负责其中 GDN Norm+SiLU 行段。修改共享 import 或公共接口时，A/C 必须互相 review。

page784 仍有可读重构空间，但不能用空白压缩代替分工。保留当前四行/CTA 自定义 merge 时，预计可去除约 15--25 行重复样板；改用官方 `merge_attn_states` 可减少更多代码，但 launch 结构不同，必须先做相同输入消融。无论是否继续精简，page784 的 pack layout、两次 attention 和 LSE merge 都由 B 一人维护，避免跨负责人协议和合并冲突。

3. 命中的 Qwen layer

Qwen3.5-27B 的 64 个 decoder layer 中：

- `full_attention`：层 `[3, 7, 11, 15, 19, 23, 27, 31, 35, 39, 43, 47, 51, 55, 59, 63]`，共 16 层。
- `linear_attention`：其余层，即 `0 <= i < 64 and i % 4 != 3`，共 48 层。
- dense MLP：全部 `0..63` 层都有一组 `Qwen3NextMLP`。

优化	实际命中的类/权重	层范围	阶段
GQA6	<code>Qwen3NextAttention.attn</code> ，Q24/KV4/D256	16 个 <code>full_attention</code> 层	单请求 prefill

优化	实际命中的类/权重	层范围	阶段
page784	同一 <code>Qwen3NextAttention.attn</code> 的 later-prefill; B 负责完整执行路径	16 个 <code>full_attention</code> 层	context 已有至少 784 token 的 prefill
GDN Norm+SiLU	<code>Qwen3_5GatedDeltaNet.norm(core_attn_out, z)</code>	48 个 <code>linear_attention</code> 层	prefill 和 decode
K5120 QKV	<code>Qwen3NextAttention.qkv_proj</code> , weight <code>(14336,5120)</code>	16 个 <code>full_attention</code> 层	单 token decode
K5120 GDN QKVZ	<code>Qwen3_5GatedDeltaNet.in_proj_qkvz</code> , weight <code>(16384,5120)</code>	48 个 <code>linear_attention</code> 层	单 token decode
K5120 GDN BA	<code>Qwen3_5GatedDeltaNet.in_proj_ba</code> , weight <code>(96,5120)</code>	48 个 <code>linear_attention</code> 层	单 token decode
K5120 GateUp/ SwiGLU	<code>Qwen3NextMLP.gate_up_proj</code> , weight <code>(34816,5120)</code>	全部 64 层	单 token decode
K5120 LM head	<code>ParallelLMHead</code> , weight <code>(248320,5120)</code>	decoder 之后一次	需要 logits 的 decode step

这些输出维度直接由模型配置得到：

```
full-attention QKV+gate = 2*24*256 + 2*4*256 = 14336
GDN QKVZ                = 2*(16*128) + 2*(48*128) = 16384
GDN BA                  = 2*48 = 96
MLP GateUp              = 2*17408 = 34816
LM head                 = vocab_size = 248320
```

调用链

```
full_attention layer
-> Qwen3NextAttention.forward
-> Attention backend
-> A: RocmAiterUnifiedAttentionImpl 公共 gate 与路径路由
-> B: page784 gate、metadata、residual pack、两次FlashAttention 与 LSE merge
    (命中即返回)
-> A: GQA6 prefill (page784 不命中时)
-> 官方 AITER unified_attention (宿主 gate 不命中时)

linear_attention layer
-> Qwen3_5GatedDeltaNet.forward
-> 官方 gdn_attention_core
-> A: qwen35_gdn_rmsnorm
-> 官方 out_proj

单 token linear/MLP/logits
-> C: qwen35_k5120_gemv
-> 官方 _rocm_C.LLMM1 ABI
-> C: qwen35_gemv_k5120
-> 不命中时继续官方 GEMM/MLP 路径
```

4. A：GQA6、attention 公共入口与 GDN Norm+SiLU

A 的实现范围、官方源码参照、代码索引、专项验收和构建命令已拆至 [A 实现和构建文档](#)。

5. B：page784 完整执行路径

B 的实现范围、官方源码参照、代码索引、专项验收和构建命令已拆至 [B 实现和构建文档](#)。

6. C：K5120、GateUp/SwiGLU 与 native 接入

C 的实现范围、官方源码参照、代码索引、专项验收和构建命令已拆至 [C 实现和构建文档](#)。

7. 构建、少量数据验证与合并

7.1--7.4 分工实现与专项构建

原第 7.1 通用构建命令已经复制进每份分工文档；原第 7.2、7.3、7.4 专项命令分别移入 A、B、C 文档，使每位负责人只阅读一份文档即可完成实现、构建和算子验收。

负责人	独立文档	包含的原章节
A	GQA6、attention 路由与 GDN	4、7.1、7.2
B	page784	5、7.1、7.3
C	K5120、GateUp/SwiGLU	6、7.1、7.4

7.5 小数据服务冒烟（DP1/DP2）

先用少量数据验证“新 wheel -> 服务 -> 路由 -> kernel -> HTTP 答案”的闭环。脚本生成 4880-token 文本，chat template 后本轮实际为 4892 tokens；在 `max_num_batched_tokens=4096` 下会形成首个 4096-token prefill 和后续 chunk，从而覆盖 GQA6、page784、GDN，并在单 token decode 覆盖 K5120/GateUp/SwiGLU。该步骤不是吞吐测试。先在任意终端设置共同路径；`SITE_DIR` 必须指向对应分工文档 2.1 刚安装的新 wheel：

```
REPO_ROOT=/public/home/tangyu408/Qwen_DCU_Worker_0/pra2026-bh408-gqa-page784-k5120
MODEL_DIR=/root/Qwen3.5-27B
SMOKE_SCRIPT="$REPO_ROOT/docs/cscs/smoke_qwen35_service.py"
```

DP1 服务终端：

```
DP1_ROOT="$ARTIFACT_ROOT/service-dp1-eager"
mkdir -p "$DP1_ROOT"/{triton,inductor,vllm,pycache}
RUN_DIR="$(mktemp -d /tmp/qwen35-dp1-run.XXXXXX)"
cd "$RUN_DIR"
export HIP_VISIBLE_DEVICES=0
export PYTHONPATH="$SITE_DIR"
export TRITON_CACHE_DIR="$DP1_ROOT/triton"
export TORCHINDUCTOR_CACHE_DIR="$DP1_ROOT/inductor"
export VLLM_CACHE_ROOT="$DP1_ROOT/vllm"
export PYTHONPYCACHEPREFIX="$DP1_ROOT/pycache"
export VLLM_ROCM_USE_AITER=1
export VLLM_ROCM_USE_AITER_UNIFIED_ATTENTION=1
export NO_PROXY=127.0.0.1,localhost
export no_proxy=127.0.0.1,localhost
unset HTTP_PROXY HTTPS_PROXY ALL_PROXY http_proxy https_proxy all_proxy
python3 -m vllm.entrypoints.cli.main serve "$MODEL_DIR" \
  --served-model-name Qwen3.5-27B --port 18011 --trust-remote-code \
  --dtype bfloat16 --tensor-parallel-size 1 --block-size 784 \
```

```
--max-num-seqs 128 --max-num-batched-tokens 4096 \
--gpu-memory-utilization 0.95 --enforce-eager \
--default-chat-template-kwarg '{"enable_thinking":false}' \
--reasoning-parser qwen3 --enable-auto-tool-choice \
--tool-call-parser qwen3_coder 2>&1 | tee "$DP1_ROOT/server.log"
```

DP1 请求终端只发 1 条数据：

```
python3 "$SMOKE_SCRIPT" \
--base-url http://127.0.0.1:18011 --model Qwen3.5-27B \
--tokenizer "$MODEL_DIR" --requests 1 --target-prompt-tokens 4880 \
--output "$DP1_ROOT/smoke.json"
```

JSON 中 `contains_expected_code` 为 `true` 后，在服务终端按 `Ctrl-C` 正常停止。确认进程退出后再启动 DP2。

DP2 服务终端：

```
DP2_ROOT="$ARTIFACT_ROOT/service-dp2-eager"
mkdir -p "$DP2_ROOT"/{triton,inductor,vllm,pycache}
RUN_DIR="$(mktemp -d /tmp/qwen35-dp2-run.XXXXXX)"
cd "$RUN_DIR"
export HIP_VISIBLE_DEVICES=0,1
export PYTHONPATH="$SITE_DIR"
export TRITON_CACHE_DIR="$DP2_ROOT/triton"
export TORCHINDUCTOR_CACHE_DIR="$DP2_ROOT/inductor"
export VLLM_CACHE_ROOT="$DP2_ROOT/vllm"
export PYTHONPYCACHEPREFIX="$DP2_ROOT/pycache"
export VLLM_ROCM_USE_AITER=1
export VLLM_ROCM_USE_AITER_UNIFIED_ATTENTION=1
export NO_PROXY=127.0.0.1,localhost
export no_proxy=127.0.0.1,localhost
unset HTTP_PROXY HTTPS_PROXY ALL_PROXY http_proxy https_proxy all_proxy
python3 -m vllm.entrypoints.cli.main serve "$MODEL_DIR" \
--served-model-name Qwen3.5-27B --port 18012 --trust-remote-code \
--dtype bfloat16 --tensor-parallel-size 1 --block-size 784 \
--data-parallel-size 2 --data-parallel-backend mp \
--max-num-seqs 128 --max-num-batched-tokens 4096 \
--gpu-memory-utilization 0.95 --enforce-eager \
--default-chat-template-kwarg '{"enable_thinking":false}' \
--reasoning-parser qwen3 --enable-auto-tool-choice \
--tool-call-parser qwen3_coder 2>&1 | tee "$DP2_ROOT/server.log"
```

DP2 请求终端并发 2 条数据，分别验证两个副本：

```
python3 "$SMOKE_SCRIPT" \
--base-url http://127.0.0.1:18012 --model Qwen3.5-27B \
--tokenizer "$MODEL_DIR" --requests 2 --target-prompt-tokens 4880 \
--output "$DP2_ROOT/smoke.json"
```

这里的 `--enforce-eager` 是 vLLM 官方功能开关，只用于少量数据的功能冒烟；目标 Triton/HIP kernel 仍真实执行和 JIT，但本轮耗时不能作为性能结果。正式吞吐测试必须去掉该开关、完成冷/热缓存，并覆盖 4--8K、8--16K、16--32K 全数据。在任何 OOM、worker 重启、异常 fallback 或重复 JIT 消除前，不得开始正式计时。

7.6 2026-08-10 实测记录

本轮没有下载或替换依赖，直接使用比赛容器中的官方配套包：

组件	实测版本/入口
vLLM	0.18.1+das.dtk2604

组件	实测版本/入口
PyTorch	2.10.0+das.opt1.dtk2604.20260325.g6b060a
Triton	3.4.0+git1ef59765
FlashAttention	2.8.3+das.opt1.dtk2604.torch2100.20260330.g3f0061， flash_attn.flash_attn_interface.varlen_fwd_unified
AITER	0.1.dev1+g9daa788.d20260401
设备	gfx936:sramecc+:xnack-

新构建和 native extension 身份：

项目	实测值
wheel	/tmp/qwen35-focused-wheel-20260810-r7/dist/vllm-0.18.1+das.dtk2604-cp310-cp310-linux_x86_64.whl
wheel SHA256	ecc3bf7b86c74d550e1f9a9c80dde10665a9ac13f2bcd561914d6a8be83f8c10
隔离导入	/tmp/qwen35-focused-wheel-20260810-r7/site/vllm/_init__.py
新 _rocm_C	/tmp/qwen35-focused-wheel-20260810-r7/site/vllm/_rocm_C.abi3.so
_rocm_C SHA256	4226920e3de4ec0188de61b0b54d28b6c55225755283868189c9e2c249df5fe1

从源码树外导入该隔离 site，确认 `vllm` 和 `_rocm_C` 都来自上述 r7 目录；wheel 内所有 相关 Python 文件也与本工作树逐字节一致。 `verify_qwen35_optimizations.py all` 使用全新 Triton cache 运行，schema 为 `qwen35-focused-small-matrix-v3`，少量算子矩阵全部通过：

优化	覆盖	最大绝对误差	结果
GQA6	4组普通cache和1组交错cache	0.015625；交错cache为0.00390625	pass
page784	context= 784/800，含1组交错cache	0.00390625	pass
page784 fallback	4个边界，均返回 False 且输出不变	0	pass
GDN Norm+SiLU	T= 16/32/64/128/4096	0	pass
GDN fallback	非目标 stride	0	pass
K5120	M= 96/14336/16384/34816/248320	0.0078125	pass
GateUp/SwiGLU	输出维度 17408	0.0625	pass
K5120 fallback	dtype/stride/shape/bias/expert gate 矩阵	0	pass

服务级少量数据结果：

模式	请求	实际 prompt / completion	答案	HTTP墙钟	结果
DP1	1	4892 / 8	9342002	129.678 s	HTTP 200，精确匹配
DP2	2 并发	每条 4892 / 8	两条均为 9342002	15.753 s	ApiServer 0/1 各完成一条，精确匹配

两次服务都显式设置目标环境变量和 `--block-size 784 --enforce-eager`，日志确认选择 `ROCM_AITER_UNIFIED_ATT_N`。DP1使用全新cache冷JIT，engine初始化约192.31 s；请求完成后生成了 `_gqa6_prefill`、`_pack_page784`、`_merge_page784` 三个kernel cache文件。DP2为减少重复JIT，将已验证的DP1 Triton cache复制为起点，约38.7 s完成初始化；因此上表墙钟只证明功能闭环，不能比较DP1/DP2性能。DP1/DP2日志扫描均未发现traceback、OOM、worker重启或EngineCore failure，并已在请求完成后正常停止。结果保存在：

- `/tmp/qwen35-focused-wheel-20260810-r7/operator-validation.log`

- `/tmp/qwen35-focused-wheel-20260810-r7/service-dp1/{server.log,smoke.json}`
- `/tmp/qwen35-focused-wheel-20260810-r7/service-dp2/{server.log,smoke.json}`
- `/tmp/qwen35-focused-wheel-20260810-r7/service-dp1/triton/` 中的三个目标kernel cache证据

额外停止线：本轮也尝试了 `compile_sizes=[4096]` 的非 eager 启动。两段图成功编译，但官方 runner 的 M-RoPE position buffer 按设计具有 `(4097,1)` 非连续 stride，而本环境 Torch AOT 图把它固化为 `(4096,1)`，在 profile 阶段触发 stride assertion。该问题位于官方 `vllm/v1/worker/gpu_model_runner.py` 的 M-RoPE buffer/compile 交界，不是上述算子数值失败。因此本节只确认官方 eager 功能闭环；在这个 AOT stride 问题解决并重新验证前，不能把本轮结果写成正式性能数据或“DP2 全量完成”。

7.7 合并顺序

建议按下面顺序集成，便于定位回归：

1. C 先提供公共 gfx936 设备门和 `gfx936.py` 模块骨架；A/B 只消费该接口。
2. B 独立完成 page784 的 `gate -> pack -> two FA -> merge -> bool` 路径。
3. A 接 GQA6 和 attention 宿主 gate/router，并保持 `page784(True) -> return`、`page784(False) -> GQA6`、宿主 gate 不命中走 official。
4. C 启用 `_rocm_C`，接普通 K5120，再单独接 fused GateUp/SwiGLU。
5. A 最后接 GDN Norm+SiLU；它不应改变 GDN core/state，也不应与 C 的输入投影冲突。
6. 每合一项先做 same-input 算子正确性，再使用全新 wheel、`.so` 和编译缓存做服务测试。

联合完成标准：

- `git diff --check`、Ruff、Python compile 和改动行的 clang-format 通过。
- 可执行实现churn相对 `fa718036` 为626（经允许超过原600目标26行）；77行代码注释和 `docs/` 不计入预算。禁止通过压缩空白字符降低该数字。
- 4-8K、8-16K、16-32K 固定请求精度全部通过，再执行 DP2 全量测试。
- decode 验证必须同时覆盖 full-attention 层、linear-attention 层、全部 MLP 和 LM head，不能只证明某一个 `(M,5120)` microbenchmark 成功。
- 任一 shape、stride、dtype 或功能开关不满足时，结果必须来自官方 fallback。

7.8 备注：可能出问题的位置与验收检查

下面的内容用于失败定位和最终验收，不要混入各分工文档 2.1 的主构建命令。

- **临时目录已存在：** `git worktree add` 或 wheel 安装会拒绝复用旧目录。确认没有服务或构建进程使用它后，清理旧 worktree，或给 `/tmp/qwen35-build-source` 和 `/tmp/qwen35-build` 加新的后缀。
- **改动没有进入 wheel：** 临时 worktree 只包含 `HEAD`；构建前应先提交要验证的改动。如果 wheel 中的 Python 文件与开发目录不同，优先检查这一项。
- **误从开发目录导入：** 在仓库目录执行 Python 时，当前目录会遮蔽 `PYTHONPATH`。应从 `/tmp` 等源码树外运行；`vllm.__file__` 和 `vllm._rocm_C.__file__` 都必须位于同一个 `/tmp/qwen35-build/site`。
- **复用了旧 native 库：** C 修改后必须重新构建 wheel。记录 wheel 和 `site/vllm/_rocm_C.abi3.so` 的 SHA256；K5120 测试日志也会打印实际 `.so` 路径和哈希。
- **依赖或编译器缺失：** 当前实测依赖为 PyTorch `2.10.0+das.opt1.dtk2604.20260325.g6b060a`、Triton `3.4.0+git1ef59765`、FlashAttention `2.8.3+das.opt1.dtk2604.torch2100.20260330.g3f0061`、AITER `0.1.dev1+g9daa788.d20260401`；编译器使用容器中的 `hipcc`、CMake 和 Ninja。不要执行 `pip install` 下载替代包。

- **服务未命中目标 attention**：必须同时设置 `VLLM_ROCM_USE_AITER=1`、`VLLM_ROCM_USE_AITER_UNIFIED_ATTENTION=1`，并传入 `--block-size 784`。日志应出现 `Using ROCM_AITER_UNIFIED_ATTN attention backend`；缺少环境变量会回到默认 backend，缺少 page size 会在 hybrid KV cache 初始化时报错。
- **连续cache假通过**：比赛hybrid KV cache可能是交错view；只用 `torch.empty` 直接创建 `(pages, 784, 4, 256)` 会掩盖地址错误。GQA6/page784专项必须额外从 `(pages, 2, 784, 4, 256)` 切出K/V，并与官方FA比较；当前记录的 stride是 `(1605632, 1024, 256, 1)`。
- **答案正确但fast path未命中**：HTTP答案可能来自官方fallback。目标服务请求完成后，除日志中的backend名称外，还要在本轮 `TRITON_CACHE_DIR` 确认新生成 `_gqa6_prefill`、`_pack_page784` 和 `_merge_page784` 缓存文件。
- **AITER 函数签名不一致**：本容器官方 AITER 的 `unified_attention` 不接收 `sinks` 和 `output_scale`。本目标版本声明不支持这两个融合能力，并且 Qwen3.5-27B 两项实际均为 `None`；如果换成 sink attention 或输出量化模型，应改走支持这些参数的官方 backend。
- **小数据通过但不能计时**：`--enforce-eager` 仅用于功能闭环。冷 JIT、启动 profile 和 HTTP 墙钟都不是吞吐数据；正式性能测试需去掉该开关并完成冷/热缓存区分。
- **非 eager 在 profile 阶段失败**：本环境曾因官方 M-RoPE position buffer 的 `(4097, 1)` stride 与 AOT 图固化的 `(4096, 1)` 不一致而停止。这是正式吞吐测试的停止线，不能把 eager 冒烟写成“DP2 全量完成”。
- **最终检查**：依次确认 `git diff --check`、Ruff、Python compile、C++ 格式、`verify_qwen35_optimizations.py all`（含交错cache）、DP1一条请求、DP2两条并发请求，并检查三个 attention kernel的命中证据；服务日志不得出现traceback、OOM、worker重启 或EngineCore failure。