

Qwen 初赛与决赛题目简述

共同目标

在国产 DCU 上使用 vLLM 0.18.1 部署 Qwen3.5-27B (BF16)，通过统一的 OpenAI 兼容接口完成长上下文在线推理。在保证模型精度、请求完成率以及 TTFT/TPOT 长尾时延约束的前提下，尽可能提高输出吞吐量 (output token/s)。

性能评测包含 4-8K、8-16K 和 16-32K 三个输入长度区间。**三个区间是三个相互独立的 benchmark，而不是将不同长度请求混合在同一条请求流中测试。** 每档分别配置吞吐测试参数、运行压测、保存结果并统计吞吐与时延。精度测试覆盖问答、摘要、检索和聚合四类任务。模型权重、tokenizer、chat template、请求内容、输出长度和采样语义等任务定义保持不变。

初赛题目

初赛采用单卡 DCU。三个长度区间分别独立评测，但各档并发数均固定为 1。参赛者主要从 vLLM 源码、执行路径和 DCU 算子层面优化，包括 KV Cache 与显存管理、PagedAttention、Attention/Linear 内核、算子融合、kernel launch 及数据搬运等。

初赛的核心特点是：服务端与压测端关键参数基本锁定，重点考察在固定负载下的实现优化。三档吞吐得分权重分别为 20%、50% 和 30%；任一档 TTFT P99 或全局 TPOT P99 超过对应 baseline 的 1.5 倍时，该档吞吐得分清零，最终成绩还会乘以四类任务的精度系数。

决赛题目

决赛改为双卡 DCU，并在初赛优化范围上增加“并行拓扑与负载配置联合搜索”。当前 baseline 位于 </public/home/tangyu408/csc-cc-testdata-20260812>，默认配置为：

- TP=2、DP=1，`max-model-len=32768`；
- `max-num-seqs=128`、`max-num-batched-tokens=4096`、`gpu-memory-utilization=0.95`；
- baseline 分别运行三个长度 benchmark，但三档默认值恰好都设为并发 10、`request-rate=inf`、最大输出长度 1024；
- 吞吐数据量依次为 80、70 和 60 条请求。

决赛扩大后的搜索空间包括：

1. **TP/DP 拓扑可通过环境变量选择**：重点比较双卡下的 TP=2、DP=1 与 TP=1、DP=2。三个长度档是独立 benchmark，因此可为每档重新启动服务并选择该档拓扑。当前原始 baseline 仍硬编码 TP=2；环境变量化属于决赛扩大搜索空间后的启动接口。
2. **服务端并发容量参数解锁**：`max-num-seqs`、`max-num-batched-tokens` 和 `gpu-memory-utilization` 改为环境变量，可针对每个独立长度 benchmark 分别调优。baseline 的 128、4096 和 0.95 是默认起点，不是决赛必须保持的值。`max-model-len=32768` 仍固定，不能借此缩短输入或减少实际工作量。
3. **客户端并发按长度独立设置**：4-8K、8-16K、16-32K 各自拥有独立的 `max-concurrency`，不再共享决赛原始脚本中的单个全局 `CONCURRENCY`。例如分别使用 `CONCURRENCY_4_8K`、`CONCURRENCY_8_16K` 和 `CONCURRENCY_16_32K`。`request-rate=inf` 作为决赛到达模型保持固定。
4. **按档独立执行与统计**：每档使用自己的数据集、服务端并发配置、客户端并发配置和结果目录，依次完成“启动服务—运行该档压测—保存该档结果”。三档请求不混跑，各自生成吞吐和 TTFT/TPOT 结果；若计分规则要求汇总某项统计量，只在计分阶段处理独立结果，不改变三档独立 benchmark 的性质。
5. **精度和任务语义参数固定**：模型权重与结构、tokenizer、BF16 dtype、chat template、temperature=0、输出长度 1024、请求内容、停止条件、服务接口、精度数据集、OpenCompass 配置、后处理和精度系数计算均不得修改。

因此，决赛的核心问题可概括为：对每个长度 benchmark，分别在两张 DCU 的资源约束下选择 **并行拓扑 (TP/DP) × 服务端并发容量 × 客户端并发负载**，并结合合法的源码、KV Cache 与算子优化，在固定精度语义、服务稳定性和时延达标的条件下最大化该档输出吞吐量。三个 benchmark 分别调优和评测，最后再按比赛规则汇总成绩。

初赛参数限制与决赛脚本变化

初赛技术方案明确锁定模型与分词、上下文和 batch scheduler、生成参数、服务接口以及 benchmark 统计口径。下面把初赛脚本快照与决赛 baseline 脚本逐项对照：

类别	参数	初赛	决赛 baseline	判断
硬件/拓扑	TP、DP	单卡，TP=1、DP=1	双卡，TP=2、DP=1	已改变；决赛新增的服务端搜索重点是 TP/DP 拓扑
模型与接口	model、tokenizer、served model、API 路由、BF16、chat template	固定	与初赛相同	继续锁定
上下文	max-model-len	规则固定为 32768	脚本显式设置 32768	继续锁定
调度容量	max-num-seqs	固定为 128，规则明确禁止修改	baseline 默认值仍为 128	决赛改变：作为并发容量参数解锁，可通过环境变量搜索
调度容量	max-num-batched-tokens	固定为 4096，规则明确禁止修改	baseline 默认值仍为 4096	决赛改变：作为批处理容量参数解锁，可通过环境变量搜索
其他服务配置	gpu-memory-utilization	脚本为 0.95	baseline 默认值仍为 0.95	决赛改变：作为显存/并发容量参数解锁
客户端负载	max-concurrency	固定为 1	环境变量 CONCURRENCY，默认 10	已改变；扩大为多请求负载，增强版再按长度拆成三个变量
到达模型	request-rate	固定为 1	固定为 inf	已改变为新的固定负载口径，不等于允许任意搜索
生成与精度语义	dtype、temperature、max_tokens /输出长度	BF16、temperature=0，输出长度固定	BF16、temperature=0，custom-output-len=1024	继续锁定
数据顺序	dataset、完整请求数、no-oversample、disable-shuffle	固定	保持同类设置，三档分别运行	继续锁定；减少请求数仅用于本地调试，不用于正式计分
统计口径	warmup、percentile、结果解析	固定	仍为 2 个 warmup，统计 P50/P95/P99 等	继续锁定

需要特别区分“baseline 默认值”和“决赛搜索权限”：决赛 baseline 仍使用 max-num-seqs=128、max-num-batched-tokens=4096 和 gpu-memory-utilization=0.95，这只代表默认起点没有变化。决赛扩大搜索空间后，并发和资源容量相关参数改为环境变量，因此上述参数与 TP/DP、客户端并发一起解锁；模型精度和任务语义相关参数则继续固定。

max-num-seqs 和 max-num-batched-tokens 分别限制单次调度的序列数和 token 预算，并不直接规定单请求输出长度。输出长度仍由固定的请求输出上限、EOS/停止条件及 max-model-len 共同决定。因此，决赛可以开放这两个并发调度参数，同时继续锁定精度与生成语义；但因错误配置造成请求失败、超时或输出变化，仍须接受完成率、SLA 和精度门禁。

计分公式

对长度档位 $i \in \{4\text{-}8\text{K}, 8\text{-}16\text{K}, 16\text{-}32\text{K}\}$ ，令 T_i 、 B_i 分别为参赛方案与 baseline 的输出吞吐量，三档满分 M_i 依次为 20、50、30。

$$r_i = \frac{T_i - B_i}{B_i}$$
$$S_i = M_i [0.60 + 0.40(1 - e^{-1.3r_i})]$$

r_i 按小数代入，例如提升 20% 时 $r_i = 0.20$ 。仅在该档通过 SLA 时使用上述得分，否则 $S_i = 0$ 。

$$TTFT_{P99,i} \leq 1.5 \times TTFT_{P99,i}^{baseline} \quad TPOT_{P99,global} \leq 1.5 \times TPOT_{P99,global}^{baseline}$$

TTFT 按档判断，TPOT 汇总后取全局 P99；服务完成率下降超过 1% 时，相应档位同样清零。四类精度任务中，第 j 类的相对精度下降为：

$$\Delta_j = \frac{A_j^{baseline} - A_j}{A_j^{baseline}} \times 100\%$$

精度下降 Δ_j	系数 k_j
$\Delta_j \leq 1\%$	1.00
$1\% < \Delta_j \leq 2\%$	0.97
$2\% < \Delta_j \leq 3\%$	0.94
$3\% < \Delta_j \leq 5\%$	0.90
$5\% < \Delta_j \leq 10\%$	0.85
$\Delta_j > 10\%$	0

$$S_{final} = \left(\sum_i S_i\right) \left(\frac{1}{4} \sum_{j=1}^4 k_j\right)$$

若决赛未公布新公式，则沿用上述口径；否则以决赛规则与实际评测脚本为准。

主要区别

项目	初赛	决赛
硬件	单卡 DCU	双卡 DCU
Benchmark 组织	三个长度档独立运行	三个长度档仍独立运行，禁止混成一个请求流
客户端负载	各档并发均固定为 1， <code>request-rate=1</code>	各档分别配置并发， <code>request-rate=inf</code>
并行拓扑	TP=1、DP=1	重点搜索 TP=2/DP=1 与 TP=1/DP=2
服务端并发容量	<code>max-num-seqs=128</code> 、 <code>max-num-batched-tokens=4096</code> 固定	默认值不变，但参数解锁并可按档搜索
精度相关参数	模型、BF16、tokenizer、chat template、生成语义和精度脚本固定	全部继续固定
其他测试参数	数据、输出长度、到达模型、接口和统计口径固定	除分档并发外继续固定
优化重点	源码、调度、KV Cache 与算子优化	初赛优化 + 双卡拓扑和负载联合调优
最终目标	分别提高三个固定负载的合规吞吐	分别寻找三个 benchmark 的最优双卡配置和合规吞吐

无论初赛还是决赛，均不得通过修改模型权重或结构、降低精度、截断输入、跳过样本、减少规定输出、缓存测试答案或更改评测统计逻辑来获得成绩。决赛环境变量搜索用于并行拓扑、服务端并发容量和客户端并发负载，不用于改变精度或任务定义。

对比依据：初赛技术方案与脚本快照；决赛 `start_vllm.sh` 和 `run_throughput.sh`。